

UJIAN TENGAH SEMESTER
ANALITIK DAN VISUALISASI DATA
HEALTHCARE STROKE



Disusun oleh:

Muhammad Arzad (2509116014)

Program Studi Sistem Informasi

Fakultas Teknik

Universitas Mulawarman

2026

KATA PENGANTAR

Puji syukur penulis panjatkan kehadirat Tuhan Yang Maha Esa, karena atas rahmat dan karunia-Nya, penulis dapat menyelesaikan tugas analisis data yang berjudul **Analitik dan Visualisasi Data Healthcare Stroke** ini tepat pada waktunya.

Tugas ini disusun untuk memenuhi salah satu kewajiban akademik dalam memahami proses pengolahan data secara menyeluruh, mulai dari tahap *Business Understanding* hingga *Data Preparation* dan visualisasi. Melalui pemanfaatan dataset *Healthcare Dataset (Stroke Data)*, penulis mencoba membedah bagaimana faktor demografi, riwayat kondisi medis, serta gaya hidup pasien memberikan pengaruh nyata terhadap probabilitas risiko serangan stroke.

Penulis menyadari bahwa selesainya tugas ini tidak terlepas dari dukungan berbagai pihak. Oleh karena itu, penulis menyampaikan terima kasih kepada:

1. Bapak Dosen Pengampu mata kuliah Analitik dan Visualisasi Data yang telah memberikan bimbingan dan ilmu dalam penyusunan tugas ini.
2. Rekan-rekan mahasiswa angkatan 2025 program studi Sistem Informasi Universitas Mulawarman yang telah bertukar pikiran selama proses pengerjaan.
3. Seluruh pihak yang telah membantu, baik secara langsung maupun tidak langsung.

Penulis menyadari bahwa laporan ini masih jauh dari kata sempurna. Oleh karena itu, kritik dan saran yang membangun sangat penulis harapkan demi perbaikan di masa mendatang. Akhir kata, semoga hasil analisis ini dapat memberikan manfaat bagi pembaca dan perkembangan ilmu pengetahuan di bidang analisis data kesehatan.

Samarinda, Maret 2026

Penulis

DAFTAR ISI

KATA PENGANTAR	ii
DAFTAR ISI	iii
DAFTAR GAMBAR	v
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Tujuan Analisis	2
BAB II PEMBAHASAN	3
2.1 Business Understanding	3
2.1.1 Business Objective	3
2.1.2 Assess Situation	3
2.1.3 Analytic Goals	3
2.1.4 Project Plan	4
2.2 Data Understanding	4
2.2.1 Membuat Dataset	4
2.2.2 Melihat Struktur Data	4
2.2.3 Statistik Deskriptif	5
2.2.4 Verifikasi Kualitas Data	5
2.2.5 Inconsistensi Values	5
2.2.6 Missing Values	5
2.2.7 Duplicated Values	6
2.2.8 Outliers Values	6
2.3 Eksplorasi Data (EDA)	6
2.3.1 Comparison	6
2.3.2 Composition	7
2.3.3 Distribution	7
2.3.4 Relationship	7
2.4 Data Preparation	8
2.4.1 Inconsistent Values	8
2.4.2 Missing Values	8
2.4.3 Duplicated Values	8
2.4.4 Outliers Values	8

2.4.5 Data Reduction (dan Feature Engineering).....	9
2.4 Visualisasi Data (Tableau).....	10
2.4.1 Pie Chart.....	10
2.4.2 Bar Chart.....	11
2.4.3 Scatter Plot.....	11
2.4.4 Histogram.....	12
2.5 Dashboard	12
2.6 Hasil Analisis	13
BAB III PENUTUP	15
3.2 Saran	15

DAFTAR GAMBAR

Gambar 1 Pie Chart Proporsi Status Merokok pada Pasien Stroke.....	10
Gambar 2 Bar Chart Tingkat Kasus Stroke Berdasarkan Tipe Pekerjaan	11
Gambar 3 Scatter Plot Korelasi Usia dan BMI Terhadap Risiko Stroke.....	11
Gambar 4 Histogram Distribusi Rata-rata Kadar Glukosa Darah	12
Gambar 5 Dashboard Analisis Faktor Risiko Stroke.....	13

BAB I

PENDAHULUAN

1.1 Latar Belakang

Penyakit stroke merupakan salah satu krisis kesehatan global yang menduduki peringkat teratas sebagai penyebab utama kematian dan kecacatan permanen di seluruh dunia. Stroke terjadi ketika pasokan darah ke bagian otak terganggu atau berkurang, sehingga jaringan otak tidak mendapatkan oksigen dan nutrisi yang cukup, yang berujung pada kematian sel-sel otak dalam hitungan menit. Meskipun serangan stroke sering kali terjadi secara tiba-tiba, kondisi ini pada dasarnya merupakan akumulasi dari berbagai faktor risiko jangka panjang yang sebenarnya dapat dipantau dan dicegah. Faktor-faktor risiko ini sangat beragam, mulai dari karakteristik demografis bawaan seperti usia dan jenis kelamin, hingga riwayat medis seperti hipertensi dan penyakit jantung, serta faktor gaya hidup yang mencakup kebiasaan merokok, tingkat glukosa darah, dan Indeks Massa Tubuh (BMI).

Dalam era transformasi digital saat ini, sektor kesehatan menghasilkan volume data medis pasien yang sangat masif setiap harinya. Namun, data mentah tersebut belum dapat memberikan nilai tambah jika tidak diolah dan dianalisis lebih lanjut. Di sinilah peran krusial dari *Data Analytics* dan *Data Visualization*. Praktisi kesehatan, manajemen rumah sakit, maupun pembuat kebijakan membutuhkan alat bantu yang komprehensif untuk mengekstrak informasi berharga dari tumpukan data tersebut. Memahami korelasi antara profil demografis, rekam medis, dan gaya hidup terhadap risiko stroke menjadi sangat esensial untuk merancang strategi perawatan yang berfokus pada pencegahan (*preventive care*). Oleh karena itu, proyek analisis ini dilakukan dengan memanfaatkan *Healthcare Dataset (Stroke Data)* untuk memetakan pola dan karakteristik pasien. Melalui penerapan teknik *Data Preparation* yang teliti seperti penanganan *missing values*, pengelolaan *outlier*, dan *feature engineering* serta perancangan visualisasi data interaktif menggunakan Tableau, diharapkan proyek ini mampu menjembatani kesenjangan antara sekumpulan angka medis dengan pemahaman bisnis (*business understanding*). Hasil visualisasi ini nantinya akan dirangkum dalam sebuah *dashboard* yang memudahkan pemangku kepentingan

untuk mengidentifikasi kelompok rentan secara cepat, sehingga alokasi sumber daya kesehatan dan intervensi medis dapat dilakukan secara lebih presisi dan efisien.

1.2 Tujuan Analisis

Tujuan utama dari analisis ini adalah untuk mengidentifikasi faktor risiko dominan yang memicu kejadian stroke dan menyajikannya dalam bentuk visualisasi interaktif. Secara spesifik, analisis ini bertujuan untuk memetakan korelasi antar variabel kesehatan dan menyediakan dashboard yang dapat digunakan oleh praktisi kesehatan untuk memantau profil risiko pasien secara cepat.

BAB II

PEMBAHASAN

2.1 Business Understanding

2.1.1 Business Objective

Analisis pada dataset Stroke Prediction ini bertujuan untuk membantu memahami faktor-faktor kesehatan yang berhubungan dengan risiko stroke pada pasien. Fokus utama analisis adalah melihat pengaruh umur, hipertensi, penyakit jantung, kadar glukosa, dan BMI terhadap kemungkinan terjadinya stroke. Dengan adanya analisis ini diharapkan dapat diperoleh gambaran karakteristik pasien yang memiliki risiko stroke lebih tinggi sehingga dapat menjadi dasar untuk langkah pencegahan maupun pengembangan model prediksi pada tahap selanjutnya.

2.1.2 Assess Situation

Stroke merupakan salah satu penyakit yang memiliki tingkat risiko tinggi dan dipengaruhi oleh berbagai kondisi kesehatan. Dataset yang digunakan berisi data pasien yang mengalami stroke dan yang tidak, sehingga memungkinkan dilakukan perbandingan untuk melihat pola yang muncul dari masing-masing kelompok.

Secara umum data sudah cukup lengkap, namun terdapat beberapa nilai kosong pada kolom BMI serta jumlah data pasien stroke yang lebih sedikit dibandingkan yang tidak stroke. Kondisi ini perlu diperhatikan dalam proses analisis karena dapat mempengaruhi hasil yang diperoleh. Oleh karena itu, diperlukan proses eksplorasi data yang sistematis agar dapat menemukan faktor yang paling berpengaruh terhadap stroke berdasarkan data yang tersedia.

2.1.3 Analytic Goals

Analisis ini bertujuan untuk:

- Melihat gambaran umum dataset.
- Mengecek missing value.
- Membandingkan pasien stroke dan tidak stroke berdasarkan umur, BMI, dan kadar glukosa.
- Menentukan faktor yang paling berpengaruh terhadap stroke.

2.1.4 Project Plan

Langkah-langkah yang akan dilakukan dalam analisis:

- Data Understanding Melihat jumlah data, tipe data, dan mengecek missing value.
- Data Cleaning Menangani missing value pada kolom BMI.
- Exploratory Data Analysis (EDA) Membandingkan data stroke dan tidak stroke menggunakan visualisasi sederhana.
- Insight Menentukan faktor yang paling terlihat berpengaruh terhadap stroke.
- Persiapan Modeling Mengubah data kategori menjadi numerik jika diperlukan untuk tahap selanjutnya.

2.2 Data Understanding

2.2.1 Membuat Dataset

Langkah pertama adalah memuat dataset ke dalam Google Colab menggunakan pustaka import Pandas dll agar data siap untuk dieksplorasi.

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import plotly.express as px
import numpy as np
from sklearn.impute import KNNImputer

file = "/content/drive/MyDrive/Dataset Praktikum AVD/healthcare-dataset-stroke-data.csv"
df = pd.read_csv(file)
df
```

2.2.2 Melihat Struktur Data

Untuk mengetahui informasi dasar terkait dataset, digunakan fungsi `.info()` dan `.dtypes`.

```
df.info()
```

```
df.dtypes
```

Insight: Berdasarkan keluaran sistem, dataset ini memiliki total 5.110 baris data (entri pasien) dan 12 kolom atribut. Terdapat 3 kolom bertipe *float64* (seperti *age*, *avg_glucose_level*, *bmi*), 4 kolom bertipe *int64* (termasuk variabel *target stroke*), dan 5 kolom bertipe *object* atau kategorikal.

2.2.3 Statistik Deskriptif

Untuk melihat ringkasan statistik dari dataset, digunakan perintah `describe()`.

```
df.describe(include='all')
```

Insight: Dari hasil statistik deskriptif, terlihat bahwa rentang usia pasien di dalam dataset sangat bervariasi, mulai dari balita hingga lansia berumur 82 tahun. Selain itu, rata-rata tingkat glukosa pasien berada di angka sekitar 106 mg/dL, namun memiliki nilai maksimum yang sangat jauh mencapai di atas 271 mg/dL, yang mengindikasikan adanya persebaran data yang cukup ekstrem pada kadar gula darah.

2.2.4 Verifikasi Kualitas Data

Tahap ini dilakukan untuk memeriksa apakah terdapat masalah pada data mentah yang perlu dibersihkan pada tahap *Data Preparation*.

2.2.5 Inconsistensi Values

Dilakukan pengecekan nilai unik pada kolom kategorikal untuk melihat apakah ada format penulisan yang tidak seragam.

```
print(df['gender'].unique())  
print(df['smoking_status'].unique())
```

Insight: Pada pengecekan nilai unik, ditemukan bahwa format penulisan pada kolom *smoking_status* belum konsisten pada penggunaan huruf kapitalnya (terdapat campuran huruf kecil dan besar pada kategori tertentu), sehingga berpotensi dibaca sebagai kategori yang berbeda oleh sistem jika tidak diseragamkan.

2.2.6 Missing Values

Pengecekan nilai kosong (*Null*) dilakukan dengan menghitung persentasenya dari total keseluruhan baris.

```
pd.DataFrame(df.isna().sum() / len(df) * 100, columns=['Null Ratio in %'])
```

Insight: Hasil pengecekan menunjukkan bahwa hanya kolom bmi yang memiliki *missing values*. Terdapat sekitar 201 baris data kosong pada kolom BMI (sekitar 3,9% dari total data), sementara kolom lainnya terisi penuh 100%.

2.2.7 Duplicated Values

Pengecekan baris yang terduplikasi secara keseluruhan di dalam dataset.

```
df[df.duplicated()]
```

Insight: Hasil eksekusi kode menunjukkan *dataframe* kosong, yang berarti tidak ditemukan adanya satupun baris data pasien yang terduplikasi secara identik di dalam dataset ini.

2.2.8 Outliers Values

Perbandingan Kasus Stroke Berdasarkan Gender

sns.countplot(x='gender', hue='stroke', data=df, palette='Set2') variabel numerik.

```
plt.figure(figsize=(8, 6))
sns.boxplot(y=df['avg_glucose_level'])
plt.show()

# (Dilakukan juga boxplot untuk kolom 'bmi' dan 'age')
```

Insight: Visualisasi *boxplot* menunjukkan bahwa kolom age memiliki distribusi yang aman tanpa pencilan. Namun, pada kolom avg_glucose_level dan bmi, terdapat banyak sekali titik *outlier* yang berada jauh di atas batas atas (*upper whisker*), yang mewakili pasien-pasien dengan tingkat obesitas atau kadar gula darah yang sangat ekstrem.

2.3 Eksplorasi Data (EDA)

2.3.1 Comparison

Eksplorasi perbandingan (*Comparison*) digunakan untuk membandingkan jumlah kasus antar kategori.

```
# Perbandingan Kasus Stroke Berdasarkan Gender
sns.countplot(x='gender', hue='stroke', data=df, palette='Set2')
```

Insight: Dari grafik perbandingan (*Countplot*), terlihat bahwa jumlah pasien perempuan di dalam dataset ini secara keseluruhan lebih banyak dibandingkan laki-laki. Walaupun demikian,

proporsi kasus yang terkena stroke pada kedua kelompok gender tersebut perlu dianalisis lebih lanjut karena visualisasi menunjukkan ketimpangan pada jumlah total populasinya.

2.3.2 Composition

Eksplorasi komposisi digunakan untuk melihat proporsi atau persentase dari keseluruhan sebuah variabel kategorikal.

```
# Proporsi Status Merokok dalam Dataset
smoking_status_counts = df['smoking_status'].value_counts()
smoking_status_counts.plot(kind='pie', autopct='%1.1f%%')
```

Insight: Berdasarkan visualisasi *Pie Chart*, komposisi status merokok didominasi oleh pasien yang tidak pernah merokok (*never smoked*). Namun, terdapat porsi yang cukup besar juga pada kategori *Unknown* (tidak diketahui), yang berarti banyak pasien yang riwayat merokoknya tidak tercatat dengan baik saat pengambilan data.

2.3.3 Distribution

Eksplorasi distribusi digunakan untuk mengamati sebaran data dari variabel berjenis angka (numerik).

```
# Distribusi Usia Responden
sns.histplot(df['age'], bins=20, kde=True)
# Distribusi BMI dan Glucose Level
```

Insight: Histogram pada variabel usia (*age*) menunjukkan distribusi yang hampir merata, namun dengan sedikit lonjakan pada kelompok usia lansia (di atas 50 tahun). Sementara itu, distribusi pada tingkat glukosa (*avg_glucose_level*) terlihat sangat menceng ke kanan (*right-skewed*), di mana mayoritas pasien memiliki kadar gula normal, dan sebagian kecil lainnya berkumpul di kadar gula yang sangat tinggi (indikasi diabetes).

2.3.4 Relationship

Eksplorasi ini mencari tahu korelasi (hubungan matematis) maupun tren antara dua atau lebih variabel.

```
# Korelasi antar Variabel Numerik
sns.heatmap(data=df[['age', 'avg_glucose_level', 'bmi', 'hypertension', 'heart_disease', 'stroke']], corr(), annot=True)
```

Insight: Visualisasi *Heatmap* memberikan temuan yang sangat penting: Variabel usia (age) memiliki korelasi positif yang paling tinggi terhadap kejadian stroke dibandingkan variabel lainnya. Disusul oleh variabel tingkat glukosa, hipertensi, dan penyakit jantung. Sebaliknya, bmi memiliki korelasi matematis yang paling lemah secara langsung terhadap stroke. Pada *Scatter Plot* antara usia dan BMI, terlihat pula tren bahwa BMI cenderung meningkat pada usia paruh baya, lalu sedikit menurun pada usia senja.

2.4 Data Preparation

2.4.1 Inconsistent Values

Menangani inkonsistensi penulisan huruf pada kolom smoking_status.

```
df['smoking_status'] = df['smoking_status'].str.title()
```

Insight: Fungsi str.title() digunakan agar setiap awal kata pada kategori status merokok diawali dengan huruf kapital secara seragam (misalnya dari "never smoked" menjadi "Never Smoked"), sehingga memastikan tidak ada kategori ganda akibat *case-sensitive* saat divisualisasikan di Tableau.

2.4.2 Missing Values

Menangani data kosong pada kolom bmi menggunakan metode imputasi.

```
df['bmi'] = df['bmi'].fillna(df['bmi'].dropna().mean())
```

Insight: Karena hanya sekitar 3,9% data BMI yang kosong, menghapus baris tersebut (*drop*) dapat merugikan karena kita akan kehilangan data variabel lainnya (seperti usia dan stroke). Oleh karena itu, nilai kosong tersebut diisi menggunakan rata-rata keseluruhan BMI pasien yang ada di dataset.

2.4.3 Duplicated Values

Karena pengecekan di tahap *Data Understanding* mengonfirmasi tidak ada baris yang terduplikasi secara identik (0 duplikat), maka tahapan penghapusan duplikasi tidak perlu dilakukan.

2.4.4 Outliers Values

Menangani nilai ekstrem (pencilan) pada rata-rata kadar glukosa menggunakan metode *Interquartile Range* (IQR).

```

Q1 = df['avg_glucose_level'].quantile(0.25)
Q3 = df['avg_glucose_level'].quantile(0.75)
IQR = Q3 - Q1
lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR

df['avg_glucose_level'] = df['avg_glucose_level'].clip(lower=lower_bound,
upper=upper_bound)

```

Insight: Pasien dengan kadar gula darah ekstrem tidak dihapus karena itu bisa jadi data medis yang valid. Namun, untuk menjaga kestabilan skala visualisasi *dashboard* nanti, nilai-nilai ekstrem tersebut dibatasi (dipangkas ujungnya) menggunakan fungsi `clip()` agar nilainya tertahan pada rentang batas atas maksimum dari IQR. Hal yang sama juga diterapkan pada kolom numerik lainnya yang memiliki pencilan ekstrem.

2.4.5 Data Reduction (dan Feature Engineering)

Menghapus kolom yang tidak relevan dan menciptakan fitur baru untuk mempermudah analisis akhir.

```

# Membuat fitur tingkat risiko kesehatan bawaan
df['health_risk_score'] = df['hypertension'] + df['heart_disease']

# Membulatkan umur
df['age_rounded'] = df['age'].astype(int)

# Menghapus kolom id
df = df.drop('id', axis=1)

# Menyimpan dataset bersih
df.to_csv("[Bersih]healthcare dataset stroke data.csv", index=False)

```

Insight: Kolom `id` dibuang karena tidak memberikan makna analitik apapun terhadap risiko stroke. Sebaliknya, diciptakan kolom baru `health_risk_score` (dengan nilai 0, 1, atau 2) yang merupakan gabungan dari riwayat hipertensi dan jantung, sehingga mempermudah melihat


akumulasi risiko medis pasien. Data yang sudah direduksi dan diolah ini kemudian diekspor menjadi file .csv baru yang bersih dan siap dihubungkan ke Tableau.

2.4 Visualisasi Data (Tableau)

Setelah tahapan *Data Preparation* selesai dan dataset dinyatakan bersih, langkah selanjutnya adalah memvisualisasikan data tersebut menggunakan perangkat lunak Tableau. Visualisasi ini bertujuan untuk menggali *insight* lebih dalam mengenai karakteristik pasien dan faktor risiko stroke, agar temuan analitik dapat dipahami dengan mudah melalui representasi grafis.

2.4.1 Pie Chart


Pie Chart - Status Merokok



Gambar 1 Pie Chart Proporsi Status Merokok pada Pasien Stroke

Visualisasi *Pie Chart* di atas menunjukkan komposisi status merokok dari kelompok pasien yang telah terdiagnosis stroke. Grafik ini difilter secara spesifik hanya untuk nilai stroke = 1. Melalui visualisasi ini, dapat diamati porsi atau persentase dari masing-masing kategori perokok (*Never Smoked*, *Formerly Smoked*, *Smokes*, dan *Unknown*), sehingga instansi kesehatan dapat melihat kelompok perokok mana yang paling mendominasi kasus stroke pada dataset ini.


2.4.2 Bar Chart



Gambar 2 Bar Chart Tingkat Kasus Stroke Berdasarkan Tipe Pekerjaan

Bar Chart ini membandingkan jumlah kasus stroke berdasarkan latar belakang pekerjaan pasien (dengan filter stroke = 1). Batang grafik diurutkan secara menurun (*descending*) untuk memperlihatkan sektor pekerjaan yang memiliki tingkat kerentanan tertinggi. Informasi ini sangat relevan untuk mengidentifikasi apakah tekanan atau lingkungan dari pekerjaan tertentu (misalnya *Private* atau *Self-employed*) berkontribusi lebih besar terhadap probabilitas terjadinya serangan stroke.


2.4.3 Scatter Plot



Gambar 3 Scatter Plot Korelasi Usia dan BMI Terhadap Risiko Stroke

Scatter Plot digunakan untuk menganalisis hubungan dua variabel numerik, yaitu Usia (Sumbu X) dan Indeks Massa Tubuh / BMI (Sumbu Y). Penggunaan parameter warna (*Color*) membedakan titik data antara pasien sehat dan pasien yang terkena stroke. Visualisasi ini memvalidasi temuan korelasi sebelumnya, di mana persebaran titik warna pasien stroke dapat memperlihatkan tren apakah risiko meningkat seiring dengan bertambahnya usia dan tingginya angka BMI.

2.4.4 Histogram




Gambar 4 Histogram Distribusi Rata-rata Kadar Glukosa Darah

Histogram ini mendeskripsikan distribusi rata-rata kadar glukosa darah (*avg_glucose_level*) dari seluruh responden. Data dikelompokkan ke dalam interval atau *bins* tertentu. Pembagian warna pada batang histogram menunjukkan proporsi pasien stroke dan non-stroke pada setiap tingkat kadar gula. Hal ini membantu dalam melihat apakah ada lonjakan kasus stroke pada rentang kadar gula darah yang tergolong ekstrem (indikasi diabetes).

2.5 Dashboard

Untuk mendukung pemahaman bisnis (*Business Understanding*) secara holistik, keempat visualisasi di atas digabungkan ke dalam satu *Dashboard* yang terintegrasi dan interaktif.



Gambar 5 Dashboard Analisis Faktor Risiko Stroke

Dashboard ini dirancang dengan mengaktifkan fitur *Action Filter* (Use as Filter) pada beberapa elemen grafiknya, seperti pada *Pie Chart* dan *Bar Chart*. Tingkat interaktivitas ini memungkinkan pengguna (seperti dokter atau manajemen rumah sakit) untuk melakukan eksplorasi data secara dinamis. Sebagai contoh, apabila pengguna mengklik salah satu batang kategori pekerjaan (misal: *Private*), maka secara otomatis *Pie Chart*, *Scatter Plot*, dan *Histogram* akan menyesuaikan dan hanya menampilkan metrik profil kesehatan dari pasien yang bekerja di sektor swasta tersebut. Antarmuka ini sangat mempermudah proses identifikasi profil risiko secara spesifik dan cepat.

2.6 Hasil Analisis

Berdasarkan serangkaian proses mulai dari *Data Understanding*, *Exploratory Data Analysis* (EDA), *Data Preparation*, hingga *Visualisasi Data*, diperoleh beberapa hasil analisis utama yang menjawab *Business Objective* proyek ini, yaitu:

1. **Faktor Demografi (Usia) Sebagai Pemicu Utama:** Berdasarkan matriks korelasi dan *Scatter Plot*, usia terbukti memiliki pengaruh yang paling signifikan dan berbanding lurus terhadap peningkatan risiko stroke. Kasus stroke mayoritas terpusat pada kelompok pasien berusia lanjut (di atas 50 tahun).
2. **Kondisi Medis dan Gaya Hidup:** *Histogram* menunjukkan bahwa meskipun banyak pasien berada di rentang glukosa normal, terdapat pola di mana pasien dengan tingkat kadar gula darah yang sangat tinggi (ekstrem) memiliki persentase kerentanan stroke yang

signifikan. Selain itu, fitur *health_risk_score* membuktikan bahwa pasien dengan akumulasi penyakit penyerta (hipertensi dan penyakit jantung) jauh lebih berisiko.

3. **Pengaruh Profil Pekerjaan:** *Bar Chart* memvalidasi bahwa terdapat ketimpangan distribusi kasus stroke pada sektor pekerjaan tertentu. Kelompok pekerjaan tertentu mendominasi jumlah kasus, yang bisa mengindikasikan faktor stres pekerjaan, kebiasaan duduk terlalu lama, atau gaya hidup di sektor tersebut kurang mendukung kesehatan sirkulasi darah.
4. **Optimalisasi Tindakan Preventif:** Melalui interaktivitas *Dashboard* yang telah dibangun, instansi kesehatan kini memiliki landasan berbasis data (*data-driven*) untuk merancang program preventif. Edukasi kesehatan, kampanye kontrol gula darah, dan pemeriksaan rutin dapat dialokasikan lebih spesifik pada demografi usia paruh baya dan sektor pekerjaan yang teridentifikasi memiliki kerentanan paling tinggi.

BAB III

PENUTUP

3.1 Kesimpulan

Berdasarkan serangkaian proses analisis data yang telah dilakukan terhadap *Healthcare Dataset (Stroke Data)*, mulai dari tahapan *Business Understanding*, *Data Preparation*, hingga *Visualisasi Data*, dapat disimpulkan bahwa penerapan metode analitik data yang terstruktur sangat efektif dalam mengekstrak wawasan bernilai dari data rekam medis mentah. Melalui proses pembersihan data yang presisi, analisis korelasi dan visualisasi berhasil mengidentifikasi bahwa usia merupakan prediktor paling dominan terhadap risiko serangan stroke. Kerentanan pasien terhadap stroke ini juga terbukti semakin meningkat apabila disertai dengan kondisi medis penyerta (*comorbidities*) seperti hipertensi, penyakit jantung, serta tingkat rata-rata glukosa darah yang ekstrem. Pada tahap akhir, perancangan antarmuka *Dashboard* menggunakan Tableau telah berhasil merangkum temuan multidimensi tersebut menjadi representasi visual yang interaktif dan mudah dipahami. Fitur interaktivitas pada *dashboard* ini memfasilitasi praktisi kesehatan untuk menelusuri data secara dinamis berdasarkan demografi, profil pekerjaan, maupun parameter gaya hidup, sehingga sangat mendukung perumusan strategi tindakan preventif yang presisi dan berbasis data (*data-driven decision making*).

3.2 Saran

Untuk mengoptimalkan pemanfaatan data ini di masa mendatang, baik dari segi akademis maupun penerapan bisnis di sektor kesehatan, penulis memberikan beberapa saran:

1. **Bagi Instansi Kesehatan (Praktisi Medis):** Hasil visualisasi dan *dashboard* ini sebaiknya digunakan sebagai landasan untuk memprioritaskan program tindakan preventif (*preventive care*). Rumah sakit atau klinik dapat lebih gencar melakukan kampanye edukasi dan penawaran *medical check-up* rutin yang secara spesifik ditargetkan pada kelompok pekerja rentan dan kelompok usia paruh baya ke atas.
2. **Pengembangan Analitik Lanjutan:** Mengingat proyek ini berfokus pada Eksplorasi Data (EDA) dan Visualisasi, untuk penelitian selanjutnya sangat disarankan agar data yang sudah bersih ini diolah menggunakan algoritma *Machine Learning*. Pembuatan model

prediktif klasifikasi (seperti *Random Forest* atau *Logistic Regression*) akan memungkinkan sistem untuk mendeteksi probabilitas stroke seorang pasien baru secara otomatis.

3. **Pengayaan Dataset:** Analisis di masa depan akan lebih komprehensif apabila dataset diperkaya dengan variabel rekam medis tambahan yang relevan, seperti riwayat genetik/keluarga, tingkat stres harian pasien, maupun data rekam diet dan aktivitas fisik (olahraga), agar pemetaan profil risiko menjadi jauh lebih akurat.